Especificaciones del proyecto

MA-3405Estadística

I semestre del 2025

Profesor: *Esteban Ballestero Alfaro*.

Estimado estudiante, el presente documento es una guía para la elaboración del proyecto del curso que tiene **un valor del 54%** sobre la nota final. La guía incluye una descripción de cada una de las partes a realizar y la fecha de entrega. El trabajo se realizará en grupos **máximo de 5 personas**.

I Parte: explicación de los datos

Para la realización de este proyecto, cada grupo deberá hacer una revisión de varios datasets disponibles en R para uso libre. Se recomiendan las siguientes opciones, pero, si el grupo considerar que puede proponer otra base de datos, ya sea de R o externa, tiene libertad de hacerlo:

Descripción del dataset	Anotaciones
`Paquete: nycflights13` https://www.rdocumentation.org/packages/nycflights13/versions/1.0.1	Base de datos de vuelos saliendo de New York
`Paquete: Datos` https://www.rdocumentation.org/packages/datos/versions/0.3.0	Datos diversos disponibles en la base de R, cuyas variables fueron traducidas al español.
`Paquete: wooldridge` https://cran.r-project.org/web/packages/wooldridge/wooldridge.pdf	Datos econométricos en inglés, incluye diferentes variables.
`Otros paquetes de R con datasets` https://stat.ethz.ch/R-manual/R-devel/library/datasets/html/00Index.html	Recomendaciones de diferentes paquetes que contienen datasets de uso libre en R.

KD nuggets https://www.kdnuggets.com/datasets/index.html	Diferentes bases de datos. Algunas son muy grandes porque

Para cada dataset seleccionado, se debe presentar la siguiente información en el documento escrito:

Dataset: nombre

Descripción general:

Describa los aspectos más importantes relacionados con la base de datos a utilizar: lugar, si fue resultado de un trabajo de investigación u otra razón, fechas, lugares, razón que justificó la toma de los datos, etc.

Además, indique si la composición de la base de datos: tamaño, cantidad de mediciones (filas), cantidad de variables (columnas), describa cada variable (a qué se refiere la medida, unidad de medida usada), si tiene datos faltantes. Para esta sección puede apoyarse en funciones de R como *str(), summary(), recursos gráficos* como *vis_dat* entre otros ya estudiados en clase.

Adjunte el siguiente cuadro en el informe, en este se hace un resumen de las variables a utilizar y los usos que posteriormente se le darán.

Resumen de variables seleccionadas		
☐ **Una población**	☐ **Dos poblaciones**	Población 1 Población 2
Variables	**Tipo**	**Parámetro por estimar (IC)**
Var1	Cualitativa	Proporción, diferencia de proporciones
☐ **Una población**	☐ **Dos poblaciones**	Población 1 Población 2
Variables	**Tipo**	**Parámetro por estimar (IC)**
Var2	Cuantitativa	Media, varianza
☐ **Una población**	☐ **Dos poblaciones**	Población 1 Población 2
Variables	**Tipo**	**Parámetro por estimar (IC)**
Var3	Cuantitativa	Diferencia de medias
☐ **Una población**	☐ **Dos poblaciones**	Población 1 Población 2
Variables	**Tipo**	**Parámetro por estimar (IC)**
Var4	Cuantitativa	Cociente de varianzas

Tome en cuenta que:

1. Una misma variable puede ser usada en varias pruebas
2. Si desea, puede usar una variable distinta para cada prueba o variar entre el caso de una o dos poblaciones
3. En sustitución de variables cualitativas, puede usar también variables binarias o dicotómicas que cumplen una función similar (sí o no, 1 o 0, etc)

II Parte: Análisis Inferencial (IC)

1. Realice intervalos de confianza que involucren una y dos poblaciones. Al menos un IC de:
    a. Un promedio usando distribución z
    b. Un promedio usando distribución t
    c. Una proporción, una variancia
    d. Una diferencia de promedios usando distribución z
    e. Una diferencia de promedios usando distribución t
    f. Una diferencia de proporciones
    g. Un cociente de variancias
2. Deben indicar las hipótesis asumidas (por ejemplo: la población X se asume que sigue una distribución normal).
3. Deben explicar cada uno de los resultados, es decir, las conclusiones obtenidas. En el caso de dos poblaciones recuerde indicar si es posible asumir igualdad de medias, proporciones o varianzas.
4. Tome en cuenta que en las clases de **R** no se estudiaron funciones que permitieran calcular intervalos de confianza para la media o diferencia de medias de los casos donde se conoce la varianza o cuando esta no se conoce, pero el tamaño de la muestra es lo suficientemente grande ($n \geq 30$), es decir, los casos en los que el IC se calcula a partir de la distribución normal (Distribución z).

    Para trabajar los casos de intervalos de confianza de este tipo (uno para una población y otro para dos poblaciones) deberán investigar sobre cuál o cuáles funciones de R podría utilizar, por lo que se le recomienda estudiar los paquetes **`BSDA`**, **`stests`** y **`PASWR2`**.

    Para cada caso investigado, deben explicar el formato de la función y aplicarlo en el caso que estén trabajando. Sean claros en indicar si la función aplica solo para una población o para dos poblaciones, podría ser que alguna de ellas tenga usos específicos y otras sean más generales para abordar ambos casos. El siguiente ejemplo muestra una forma de proceder:

Ahora, si se automatiza el proceso, se puede usar una función de R llamada `varTest` del paquete `EnvStats` cuya estuctura sería:

```
varTest(X,conf.level)$conf.int
```

donde:

- **x**: vector que contiene la muestra de datos.
- **conf.level**: nivel de confianza.

III Parte : Análisis Gráfico

1. En esta sección deberá realizar lo siguiente:

Objeto	Especificaciones
Diagrama de caja o boxplot	1. Variable cualitativa en el eje horizontal y variable cuantitativa en el eje vertical 2. Debe contener un título descriptivo 3. Debe contener una capa con theme_minimal() 4. Debe mostrar los datos atípicos con un color diferente al usado para las cajas. 5. Genere dos diagramas de caja: uno con color degradado y otro con colores diferentes
Violinplot	Genere los violinplot para los mismos datos usados en el diagrama de cajas y con las mismas especificaciones Además, genere otro gráfico violinplot que tenga colores semitransparentes y diferentes, que se muestren los puntos y los datos atípicos (los datos atípicos con un color diferente a los puntos que quedan dentro del violinplot), theme_minimal, que contenga también las capas de los diagramas de caja. Se muestra un ejemplo de o esperado 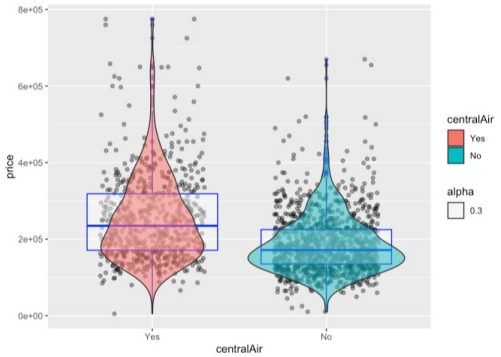
Gráficos de barras	1. Genere un gráfico de barras verticales. Estos deben contener una variable cronológica en el eje horizontal (meses, años, etc) y en el eje

	vertical las cantidades asociadas a cada característica del eje horizontal. Debe contener un título descriptivo y haga que las barras muestren un color degradado. 2. Con los mismos datos genere un gráfico lollipops, que no tenga las cantidades en las paletas 3. Genere un gráfico de barras horizontal: en el eje vertical deberá ir la variable cualitativa o categórica (no debe ser cronológica, pues para estas se usa barras verticales), las barras deberán ordenarse en forma descendente y use un color diferente para cada barra. 4. Para los mismos datos del punto (3), genere un gráfico de radar. 5. Todos los gráficos deberán contener un título descriptivo y la capa de theme_minimal()
Gráfico de pastel y dona	Genere un gráfico de pastel y dona, donde cada sección contenga un color distinto. Debe incluir un título descriptivo y theme_minimal().

En el libro Elementos para el Análisis Estadístico con Datos Ambientales usando R, al final de la sección de gráficos de pastel y donas, se recomienda la base de datos vuelos que es libre en R, por si desea considerarla como base para realizar lo gráficos que se le solicitan.

IV parte: Análisis Inferencial (pruebas de hipótesis de una y dos poblaciones)

Realice pruebas de hipótesis que involucren una y dos poblaciones. Al menos una prueba de hipótesis de:

a. Un promedio
b. Una proporción
c. Una variancia
d. Una diferencia depromedios
e. Una diferencia de proporciones
f. Un cociente de variancias

Debe indicar las conclusiones obtenidas y también las hipótesis asumidas (por ejemplo, la población X se asume que sigue una distribución normal)

V Parte: Análisis Inferencial (Otras pruebas de hipótesis)

1. Realice una prueba de Bondad de Ajuste para determinar si una de las variables cuantitativas sigue o no una distribución normal.
2. Realice una prueba de Bondad de Ajuste para determinar si una de las variables cuantitativa sigue o no una distribución no normal (escoja una que no sea normal).
3. Realice una prueba de independencia entre las variables cualitativas de una misma población.
4. Realice una prueba ANOVA entre una variable cuantitativa y otra cualitativa de una misma población. En caso de existir diferencia significativa entre algunos de los tratamientos, deberá hacer una prueba Tukey para determinar entre cuáles pares de tratamiento existe tal diferencia.
5. Debe indicar las conclusiones obtenidas

VI Parte: Análisis de regresión

1. Realice un análisis de regresión lineal entre dos variables cuantitativas de una misma población. (estimación puntual, estimación por intervalo de los parámetros, intervalo de predicción, coeficiente de correlación)
2. Escoja una regresión NO lineal (de las vistas) que se ajuste más para las variables cuantitativas de una misma población. Justifique su escogencia.
3. Realice un análisis de regresión no lineal escogida entre dos variables cuantitativas de una misma población. (estimación puntual, estimación por intervalo de los parámetros, intervalo de predicción, coeficiente de correlación
4. Realice análisis de Regresión Lineal Múltiple (RLM) y de Regresión No Lineal Múltiple (RNLM) para casos que se le suministrarán.

Fases del proyecto y detalles de entrega

	Fase 1	Fase 2	Fase 3
Valor total	%	%	%
Entrega de informe detallado del análisis realizado que involucra las partes:	Partes I, II y III Valor 14%	Parte IV Valor 14%	Parte V y VI Valor 14%
Fecha de entrega del informe:	A más tardar: **24 de abril**	A más tardar: **15 de mayo**	A más tardar: **12 de junio**
Exposicióndel trabajo realizado	Valor 4%	Valor 4%	Valor 4%

Observaciones generales:

- Los datasets y las variables elegidas en la primera fase, podrían mantenerse o cambiarse en las fases posteriores, según los requerimientos en cada una de estas.

- Se dará prioridad a los estudiantes para que conformen sus grupos de trabajo, caso contrario, el profesor asignará los miembros en cada uno de estos. Los grupos se mantendrán invariantes a lo largo del semestre. En caso de que algunos estudiantes se retiren del curso, se valorará la reasignación de los miembros de ese grupo al que pertenecían, siempre justificado en una sobrecarga de trabajo.
- Una vez definidos los grupos, se creará un canal específico para el grupo dentro del equipo del curso en la plataforma Teams. Todos los materiales que se generen como parte de este trabajo, deben concentrarse en este canal. La revisión de los proyectos se hará desde esta plataforma.
- Cada grupo deberá crear una Bitácora de minutas de cada una de las reuniones, donde en cada una de ellas aparezca el número de minuta, fecha, presentes, hora de inicio, agenda, acuerdos y hora de cierre. Se recomienda que las reuniones sean realizadas en Teams y de requerir ser grabadas, estas quedan automáticamente disponible en la sección se archivos del canal. La primera minuta deberá contener una distribución de tareas por persona y un plan de trabajo que visibilice el alcance de la meta en el plazo. Deberá haber al menos una minuta por semana a partir de la fecha en que fuese asignado el proyecto.
- El informe puede crearse en **RStudio** y exportarse como documento de **Word**. Este informe debe subirse en la sección de tareas que se creará dentro del canal privado del grupo. <u>No es necesario que se adjunten los documentos *rmd*</u>, solo en caso de que estos sean solicitados.
- Todos los cálculos numéricos o estadísticos, estimaciones, gráficos de análisis, trabajo con la base de datos, deberá realizarse en *RStudio*.
- Sobre la nota del informe en cada fase.
    - El profesor dará una nota inicial del proyecto.
    - Cada estudiante deberá valorar con un porcentaje el trabajo de cada uno de sus compañeros de equipo y su propio trabajo. Esto se debe realizar mediante un formulario al cuál se le brindará el acceso.
    - Porcentaje promedio: es el promedio ponderado de los porcentajes obtenidos para cada estudiante, como parte de la evaluación de sus compañeros y la propia.
    - La nota de cada estudiante se obtiene sacando el porcentaje promedio obtenido de la nota inicial.
    - *Ejemplo:* suponga que la fase I el grupo 1 estuvo conformado por los estudiantes A, B, C y D:

	Nota inicial del informe dada por el profesor	Valoración Del trabajo realizado dada por				Promedio de valoraciones	Nota obtenidadel informe dela fase I
		A	B	C	D		
A	90	100	100	100	100	100	90
B	90	70	70	70	90	72,67	65,4
C	90	10	60	50	40	26	23,4
D	90	100	80	90	100	96	86,4

Sobre la exposición.

- La exposición de la fase 1 y 2 se realizará fuera del horario de clase y será posterior a la revisión realizada por el profesor (se estima una semana después de la entrega). La exposición de la fase 3 se realizará en la semana 17 durante el horario de clase.
- Deben estar todos los integrantes del grupo, y pueden preparar una presentación no mayor a los 15 minutos.
- Todos los estudiantes deberán exponer de manera equitativa y **deberán mantener su cámara encendida**. En casos debidamente justificados, se hará una excepción.
- Finalizada la presentación se realizarán algunas preguntas teóricas sobre el trabajo realizado. El profesor puede elegir quien de los integrantes del grupo debe responder.
- Los temas a exponer, no necesariamente corresponderá aquél tema en el que el estudiante tuvo mayor incidencia. La distribución de los temas de la exposición será asignada previamente a esta por parte del profesor.
- Desglose de la nota (será la misma para todos los integrantes del grupo):
    - Presentación y manejo del tiempo: 50%
    - Respuesta a las preguntas: 50%