Especificaciones del proyecto Fase III

Estadística IS 2025

Prof. Esteban Ballestero Alfaro

I PARTE: OTRAS PRUEBAS DE HIPÓTESIS EN R

En esta sección se presentarán algunos casos relacionados con pruebas de hipótesis de bondad de ajuste, ANOVA´s e independencia. Deben posterior a la lectura del caso, identificar el tipo de prueba que mejor se adapte a la situación.

CASO 1:

Utilice la base de datos `KidsFeet` del paquete `mosaicData` como evidencia para realizar un estudio de normalidad de la longitud del pie (length) de los niños (**B:** boys) es igual que el de las niñas (**G:** girls). Para emitir su conclusión, siga el siguiente proceso:

- Para este ejercicio, explique como la siguiente instrucción permite agrupar los datos para niños y niñas:

```
feetsplit <- split(feet$length,feet$sex)
```

1. Para cada datset (niños y niñas), haga un estudio gráfico de la normalidad. Para esto elabore el gráfico que contenga tanto la función de densidad para cada caso como su respectiva curva normal teórica a partir de su media y desviación estándar. ¿Se puede intuir una posible normalidad para los datos? Explique brevemente.

2. Para cada dataset (niños y niñas) elabore un gráfico `QQ-plot` y haga la interpretación en cada caso desde el punto de vista si es posible asumir normalidad.

3. Realice las pruebas formales de normalidad `S-W test`, `A-D test`, `K-S-L test`.

4. ¿Es posible aplicar `D'Agostino-Pearson`?. En caso de ser posible, realice la prueba.

5. Haga un análisis de la curtosis y simetría de los datos usando las funciones respectivas del paquete `moments`. No es necesario que realice el gráfico tal como se mostró en clases, solo observe los resultados para una posterior interpretación

CASO 2:

Realice todo lo solicitado el **Caso 1**, pero utilizando los datos de `biceps` de la tabla `medidas_cuerpo`. Para obtener la base de datos, realice los siguiente:

1. Descargue la base de datos desde la url como sigue:

```
url <- 'https://raw.githubusercontent.com/fhernanb/datos/master/medidas_c
uerpo'
variable <- read.table(file=url, header=T)
```

2. Recuerde que puede darle el nombre que desee a la variable.

3. Analice cada prueba de normalidad como se solicitó en el **Caso 1**, utilizando todos los datos de la variable `biceps`, **NO** haga separación alguna por sexo u otra categoría en este análisis.

Una vez realizado todos los cálculos de las pruebas de normalidad para los **Casos 1 y 2**, complete la siguiente tabla con la información que corresponda en cada una de las celdas:

Tipo de prueba	Longitud del pie		Medidas de biceps
	Niños	Niñas	
Función de densidad versus curva normal	[Anote lo observado]	[Anote lo observado]	[Anote lo observado]
Conclusión			
QQ-Plot	[Anote lo observado]	[Anote lo observado]	[Anote lo observado]
Conclusión			
S-W test	[Valor P]	[Valor P]	[Valor P]
Conclusión			
A-D test	[Valor P]	[Valor P]	[Valor P]
Conclusión			

K-S-L test	[Valor P]	[Valor P]	[Valor P]
Conclusión			
D' Agostino - Pearson	[Valor P]	[Valor P]	[Valor P]
Conclusión			
Curtosis y simetría	[Valores]	[Valores]	[Valores]
Conclusión			
Conclusión general sobre normalidad de los datos			

CASO 3:

La siguiente tabla resume los datos de obtenidos de víctimas de crímenes elegidas al azar (según datos del Departamento de Justicia de USA):

	HOMICIDIO	ROBO	ASALTO
El criminal era un extraño	12	379	727
El criminal era un conocido o pariente	39	106	642

Con los datos anteriores, ¿sería posible considerar que el tipo de delito es independiente de la condición del delincuente?, o por el contrario, ¿existe alguna relación entre el tipo de delito con respecto a quien comete el acto? Use un nivel de significancia de 5%.

Además, complete a partir de los resultados de la prueba, lo que se solicita en la siguiente tabla:

Resumen de la prueba	
Tipo de prueba a utilizar (independencia, bondad de ajuste, ANOVA)	

Valor observado	
Grados de libertad y qué representan	
Valor P	
H_0:	
H_1:	

Conclusión:

[Indique se H_0 es rechazada o no rechaza indicando la evidencia para tal conclusión, qué significa esto en el contexto del problema dando respuesta a la pregunta planteada en este.]

CASO 4:

Analice con detenimiento la siguiente situación:

La seguridad de los automóviles se determina mediante diversas pruebas. Una de ellas consiste en hacer chocar un automóvil contra una barrera fija a 35 mi/h con un maniquí colocado en el asiento del conductor.

A una de las medidas utilizadas para cuantificar el impacto del choque sobre el conductor se le conoce como **Desaceleración de pecho** y se mide en unidades de fuerza de gravedad (g). Los valores más grandes indican mayores cantidades de desaceleración, las cuáles pueden provocar lesiones graves en los conductores. La siguiente tabla muestra mediciones de desaceleraciones de pecho obtenidas a partir de pruebas de choques de diferentes tipos de vehículos:

Autos compactos	Autos medianos	Autos grandes
44	41	32
43	49	37
44	43	38
54	41	45
38	47	37
43	44	33
42	37	38
45	34	45

50	43
	42

Con los datos anteriores, ¿es posible considerar que el tamaño del automóvil puede variar en cuanto a la seguridad de sus pasajeros o, por el contrario, es igualmente riesgoso? Use un nivel de significancia del 5%.

1. Con los datos que imprime la prueba, complete la información requerida en la siguiente tabla:

Resumen de la prueba	
Tipo de prueba a utilizar (independencia, bondad de ajuste, ANOVA)	
Valor observado	
Grados de libertad y qué representan	
SSE	
SSA	
SST	
S_1^2 y S_2^2 (use la columna de Mean Sq)	
Valor P	
H_0:	
H_1:	

Conclusión:

[Indique se H_0 es rechazada o no rechaza indicando la evidencia para tal conclusión, qué significa esto en el contexto del problema dando respuesta a la pregunta planteada en este.]

2. En caso de detectar alguna diferencia en cuanto a la seguridad que puede brindar al tamaño del vehículo, ¿es posible identificar en cuáles existe una verdadera diferencia significativa? De ser así, realice la prueba que corresponda e interprete el resultado.

II PARTE: MODELOS DE REGRESIÓN LINEAL

En esta sección se analizarán casos relacionados con los modelos de Regresión Lineal Simple (RLS) y múltiple (RLM), así como los modelos de Regresión no Lineal Simple (RNLS).

CASO 5:

Cargue los datos **EdadPesoGrasas.txt** como se muestra a continuación:

```
grasas <- read.table('http://verso.mat.uam.es/~joser.berrendero/datos/Eda
dPesoGrasas.txt', header = TRUE)
```

Para dichos datos, realice lo siguiente:

1. Elabore un análisis de correlación completo entre todas las variables y haga una interpretación de lo que observa. Debe utilizar al menos un recurso gráfico y uno numérico.

2. Seleccione las dos variables con mayor coeficiente de correlación y genere un modelo RLS de mejor ajuste para ambas variables. Defina claramente quién es la variable respuesta y quién la variable explicativa.

3. Analice la calidad del modelo generado a partir de su coeficiente de correlación y de determinación.

4. Genere un gráfico que muestre tanto los datos de dispersión como la recta de mejor ajuste. Interprete lo que observa en el gráfico.

5. Realice la prueba de normalidad para los residuos e indique si se cumple la condición.

6. Calcule el intervalo de confianza de 95% para los coeficientes del modelo.

7. Para una edad de 27 años, determine un IC de 95% para $\mu_{Y|_{x=27}}$ y un intervalo de predicción para los valores de Y asociados a dicha edad. Interprete el resultado para ambos casos.

8. ¿Es significativa la linealidad para estas variables?, ¿es posible considerar dependencia lineal entre estas? Haga la prueba de hipótesis correspondiente para responder a estas preguntas.

CASO 6:

Supóngase que el departamento de ventas de una empresa quiere estudiar la influencia que tiene la publicidad a través de distintos medios de comunicación, sobre el número de ventas de un producto. Se dispone de un conjunto de datos que contiene los ingresos (en millones) conseguido por ventas en 200 regiones, así como la cantidad de presupuesto, también en millones, destinado a anuncios por radio, TV y periódicos en cada una de ellas.

Los datos se encuentran en el archivo `DatosVentas.csv`.

Para estos datos, realice los siguiente:

- Instale y cargue las librerías `bbmle` y `DALEX`

GENERACIÓN DE LOS MODELOS

1. Genere un primer modelo denominado `mod0` el cuál será un modelo RLS, usando como variables respuesta `ventas` y como variables exploratorias a `tv`. Una vez calculados los coeficientes en `R` para las variables y el intercepto, escriba la ecuación del modelo estimado.

2. Genere, usando la función `lm` de `R`, un primer Modelo RLM donde las variables predictoras o exploratorias sean `tv`, `radio` y `periodico`, la variable respuesta `ventas`. Escriba la ecuación provisional del modelo que se desea determinar. Guarde el modelo en una variable que debe llamar `mod1`

Una vez calculados los coeficientes en `R` para las variables y el intercepto, escriba la ecuación del modelo estimado.

De los 4 coeficientes calculados en `R`, ¿cuáles de ellos son estadísticamente significativos (aportan al modelo) y cuáles no lo son? Explique su respuesta, apoyándose en los datos del modelo obtenidos en `R`.

3. Seguidamente, genere un segundo Modelo RLM usando nuevamente la función `lm`, pero en este caso contemple **SOLO** las variables cuyos coeficientes resultaron ser estadísticamente significativos en el análisis anterior. Guarde este modelo en una variable que debe llamar `mod2`. Según los datos, ¿son todos los coeficientes significativos? Justifique su respuesta.

4. Usando los mismos datos, genere un Modelo de RNLM de la forma $ventas = b_0 + b_1 tv + b_2 radio + b_3(tv * radio)$. Se recomienda usar nuevamente la función `lm` y guarde el modelo en una variable que deberá llamar `mod3`. Una vez que se tengan los datos del modelo, indique si los coeficientes calculados son estadísticamente significativos o no, justificando adecuadamente su respuesta.

SELECCIONANDO EL MEJOR MODELO

Para esta sección, deberá seleccionar el mejor modelo entre los 4 ya generados en la I Parte de esta prueba, es decir: **mod0, mod1, mod2 y mod3**.

Para hacer una adecuada escogencia, debe utilizar 4 criterios a saber:

1. Coeficiente de correlación y coeficiente de determinación

2. Criterio de Información de Akaike (**AIC**), el cual, representa una medida de la calidad relativa de un modelo estadístico, para un conjunto dado de datos. Como tal, el **AIC** proporciona un medio para la selección del modelo. AIC maneja un trade-off entre la bondad de ajuste del modelo y la complejidad del modelo, basado en el principio de que un mejor modelo debe además de la precisión, ser simple en cuanto a que debe utilizar la menor cantidad de variables predictoras (Principio de parsimonia).

3. Los residuales, que están conformados por todas las diferencias entre el valor obtenido en la muestra con respecto al estimado por el modelo. Recuerde que mientras más grande sean los residuales, más se alejan los puntos del modelo y este se vuelve menos confiable.

4. Comparación de modelos mediante Análisis de Varianzas, es decir, un ANOVA para los modelos. Para este estudio deberá usar la función `anova()` del paquete `stats`.

Una vez definida la ruta, realice lo siguiente:

1. Calcule los coeficientes de correlación y de determinación de los modelos **mod0, mod1, mod2 y mod3** y haga una comparación entre estos modelos a partir de este criterio, ¿Cuál de los 3 modelos es mejor? Explique su escogencia.

Esta información deberá ser presentada en la siguiente tabla:

Ecuación del modelo	Coeficiente de correlación (R)	Coeficiente de determinación (R^2)

2. Tome el modelo 2 (mod2) y explique el significado de los coeficientes de correlación y de determinación para ese caso.

3. Usando la función `AICctab` del paquete `bbmle`, calcule los valores del indicador `AIC` para cada uno de los modelos y con base en ellos, defina el orden de estos de mejor a peor. El criterio que debe usar es **menor AIC, mejor el modelo**. Instrucción para `R`:

```
AICctab(mod1, mod2, mod3, base = T, delta = T, sort = T, weights = T, nobs = #)
```

Nota: debe completar el parámetro `nobs` (número de observaciones), según la corresponda a la base de datos.

4. El análisis de los residuales se trabajará **solo** con los modelos `mod0`, `mod2` y `mod3` debido a que el modelo 1 y 2 resultaron ser similares. Para este trabajo debe usar algunas funciones del paquete `DALEX`. Seguidamente se detallan los pasos a seguir:

Cree los Explain Models

```
exp_lm0 <- explain(mod0, data = base de datos, label = "lm", y = variable respuesta)

exp_lm2 <- explain(mod2, data = base de datos, label = "lm", y = variable respuesta)

exp_lm3 <- explain(mod3, data = base de datos, label = "lm", y = variable respuesta)
```

Cree los Performance Models a partir de los Explain Models

```
lm0 <- model_performance(exp_lm0)
lm2 <- model_performance(exp_lm2)
lm3 <- model_performance(exp_lm3)
```

Grafique los modelos

```
plot(lm0,lm2, lm3)
```

Interprete el gráfico y escoja el mejor modelo, usando el criterio: **curva menor o más baja, es mejor**. Explique a partir del gráfico, por qué este criterio tiene sentido para justificar que un modelo es mejor que otro.

5. Finalmente, y como último criterio, realice el análisis de varianza. Para escoger el mejor modelo solamente debe tomar en cuenta el valor de Residual Sum of Squares(**RSS**), donde a menor valor, mejor es el modelo, es decir, los puntos están más ajustados.

Considere la siguiente instrucción para realizar este análisis:

```
anova(mod0,mod1, mod2, mod3)
```

III PARTE: MODELOS DE REGRESIÓN NO LINEAL

CASO 7:

Para esta sección deberá generar dos modelos de RNLS usando los datos de `bones` de la base de datos `jaws`, la cual contiene información sobre la longitud de la mandíbula de los venados, según la edad.

1. Para iniciar cargue el archivo `jaws.txt`. Asegúrese de que este archivo esté en la misma carpeta donde están los archivos creados en RStudio para el proyecto.

```
var <- read.table("nombre.txt",header=T)
```

2. Luego, construya un gráfico de dispersión para los datos:

```
ggplot(datos,aes(x = ..., y = ...)) +
  geom_point()
# en lugar de geom_point(), también puede usar geom_jitter()
```

3. Usando la función `nls()` del paquete `stats`, van a generar un modelo de RNLS de la forma $ y = a(1- e^{-c x })$. A este modelo asígnele el nombre de `model1`. Use como valores iniciales **a = 120** y **c = 0.064**. Escriba la ecuación del modelo usando los valores para los parámetros obetinos en `R`.

4. Realice el gráfico del modelo 1 (`model1`) junto con su gráfico de dispersión.

5. Deberán crear un segundo modelo a partir de los modelos estudiados en clase. Analice con detenimiento la forma de los datos y haga una selección apropiada.

6. Una vez escogido el modelo, haga un proceso de linealización y estime los parámetros a partir de un modelo de RLS.

7. Use los valores de las estimaciones de los coeficientes del modelo de RLS obtenidos en el punto anterior, como los valores iniciales para generar el modelo de RNLS a partir de la función `nls()`.

8. Genere el Modelo de RNLS y escriba la ecuación resultante. Además, realice el gráfico respectivo de este modelo junto con el gráfico de dispersión de los datos.

9. Utilice la función *anova* para comparar ambos modelos. ¿cuál modelos es el mejor?, gráficamente, ¿se puede llegar a esa misma conclusión?

Fases del proyecto y detalles de entrega

	Fase 1	Fase 2	Fase 3
Valor total	%	%	%
Entrega de informe detallado del análisis realizado que involucra las partes:	Partes I, II y III Valor 14%	Parte IV Valor 14%	Parte V y VI Valor 14%

Fecha de entrega del informe:	A más tardar: **24 de abril**	A más tardar: **15 de mayo**	A más tardar: **13 de junio**
Exposicióndel trabajo realizado	Valor 4%	Valor 4%	Valor 4%

Observaciones generales:

- Cada grupo deberá crear una bitácora de minutas de cada una de las reuniones, donde en cada una de ellas aparezca el número de minuta, fecha, presentes, hora de inicio, agenda, acuerdos y hora de cierre. La primera minuta deberá contener una distribución de tareas por persona y un plan de trabajo que visibilice el alcance de la meta en el plazo. Se adjuntará una plantilla de minuta, por si desean considerarla como base:
- El informe debe crearse en **RStudio u otra IDE de preferencia** y exportarse como documento de **Word**. Este informe debe subirse en la sección de tareas que se creará en Teams. No es necesario que se adjunten los documentos *rmd*, solo en caso de que estos sean solicitados.
- Todos los cálculos numéricos o estadísticos, estimaciones, gráficos de análisis, trabajo con la base de datos, deberá realizarse usando *R*.
- La autoevaluación, coevaluación y exposición, se rigen bajo las mismas reglas explicadas para las entregas anteriores.
- La entrega de esta fase III será para el **viernes 13 de junio** en la plataforma de Teams.